Métricas DORA em repositórios open-source populares do GitHub

Brenda Evers[1], **Carlos José Gomes Batista Figueiredo**[1], **Gabriela Alvarenga Cardoso**[1]

[1]Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brasil

{1523565, 1507022, 1026227}@pucminas.edu.br

Abstract. *DORA metrics (deployment frequency, lead time, change failure rate and time to restore) are the reference for software delivery performance, but public repositories do not record deployments or production failures. We mined them from the 300 most popular GitHub repositories that use GitHub Actions, over one year, using releases as a proxy for deployments and workflow runs as a proxy for failures. The median repository publishes 0.54 releases per week, has a lead time of about 11 days, a CI failure rate of 4.7% (17.4% when a failure is a release followed by a corrective release within 7 days) and recovers from a failed run in 2.6 hours. Deployment frequency correlates positively with the delivery-based failure rate (Spearman $\rho = 0.50$), partly by construction, and repository age is the characteristic most associated with performance. Changing the operational definitions moves 22% to 30% of the repositories to another category, and our corrective-release heuristic reached an F1 of 0.64, so per-repository values are estimates.*

Resumo. *As métricas DORA (frequência de deploy, lead time, taxa de falha de mudanças e tempo de recuperação) são a referência para medir o desempenho de entrega de software, mas os repositórios públicos não registram deploys nem falhas em produção. Neste trabalho, mineramos as quatro métricas nos 300 repositórios mais populares do GitHub que usam GitHub Actions, em um ano, com releases como aproximação de deploys e execuções de workflow como aproximação de falhas. O repositório mediano publica 0,54 releases por semana, tem lead time de cerca de 11 dias, taxa de falha de CI de 4,7% (17,4% quando a falha é uma release seguida de uma release corretiva em até 7 dias) e se recupera de uma execução com falha em 2,6 horas. A frequência de deploy tem correlação positiva com a taxa de falha por entrega (Spearman $\rho = 0{,}50$), em parte por construção, e a idade do repositório é a característica mais associada ao desempenho. Trocar as definições operacionais move 22% a 30% dos repositórios para outra categoria, e a nossa heurística de release corretiva alcançou F1 de 0,64, de modo que os valores por repositório são estimativas.*

1. Introdução

As métricas DORA (*DevOps Research and Assessment*) — frequência de deploy, lead time, taxa de falha de mudanças e tempo de recuperação — tornaram-se referência para medir o desempenho de entrega de software [Forsgren et al. 2018]. Elas classificam equipes em quatro faixas (*Elite*, *High*, *Medium* e *Low*) e associam entrega rápida e estável a

melhores resultados organizacionais [DORA 2024]. A maior parte da evidência vem de pesquisas com questionários respondidos por profissionais, e pouco se sabe sobre como projetos open-source populares se posicionam nessas faixas quando as métricas são calculadas a partir dos próprios dados do repositório.

O problema é que, em repositórios públicos, as métricas DORA não são observadas diretamente: o GitHub não registra deploys nem falhas em produção, e é preciso inferi-los a partir de aproximações (*proxies*), como releases, commits e execuções de *workflows* do GitHub Actions.

O objetivo deste trabalho é mensurar as quatro métricas DORA em repositórios populares do GitHub que usam GitHub Actions, em uma janela de um ano (01/10/2025 a 30/09/2026), e investigar como elas se relacionam entre si, como variam com características dos repositórios e quão sensíveis são às definições adotadas. Para isso, formulamos oito questões de pesquisa (RQ 01 a RQ 08): as RQ 01 a RQ 04 descrevem cada métrica; a RQ 05 trata da relação entre frequência de deploy e taxa de falha; a RQ 06, das características dos repositórios associadas a melhor desempenho; a RQ 07, da sensibilidade da classificação às definições; e a RQ 08 (bônus), do *rework rate*. As hipóteses de cada questão, escritas antes da coleta e da análise dos dados, são apresentadas a seguir.

- **RQ 01 (frequência de deploy):** a faixa *Medium* deve ser a mais comum e a *Elite*, minoria, porque muitos projetos fazem releases manuais ou por marcos, e estrelas indicam visibilidade, não cadência; a *Low* deve reunir os repositórios com 5 a 11 releases no ano.
- **RQ 02 (lead time):** de dias a poucas semanas, na maioria *Medium* e *High*, com a variante (a) maior e com mais repositórios *Low* que a (b), já que basta um commit antigo "esquecido" para elevá-la.
- **RQ 03 (CFR):** baixo na maioria dos repositórios (*Elite* ou *High*), com grande dispersão, e a variante (a) maior que a (b), por incluir testes instáveis e falhas de infraestrutura que não chegam ao usuário.
- **RQ 04 (tempo de recuperação):** menos de um dia, com mediana *High*, poucos repositórios *Elite*, IQR amplo, cauda de dias a semanas e uma parcela de episódios censurados.
- **RQ 05 (frequência e taxa de falha):** correlação fraca ($|\rho| < 0{,}3$) entre a frequência e o CFR (a), em linha com o DORA, para quem velocidade e estabilidade não são um *trade-off* [DORA 2024]; e positiva e moderada com o CFR (b), em parte por construção, já que quem publica mais tem mais chance de ter uma correção em até 7 dias. As duas variantes devem levar a conclusões diferentes.
- **RQ 06 (características associadas ao desempenho):** efeitos maiores do número de contribuidores e do tipo do projeto e pequenos de estrelas, linguagem e idade, com poucos testes significativos após a correção de Holm.
- **RQ 07 (sensibilidade às definições):** 20% a 40% dos repositórios mudam de categoria em cada par de combinações, quase sempre para uma vizinha, com kappa ponderado moderado a substancial; C2 e C3 levam a categorias melhores que C1, porque pré-releases e tags aumentam a frequência e o lead time (b) tende a ser menor que o (a); a maior divergência fica em C1$\times$C2, que muda as três definições (unidade de deploy, lead time e CFR), e a menor em C2$\times$C3, que, como C1$\times$C3, muda duas, mas compartilha a variante (b) do lead time, uma escolha

que esperamos ter grande efeito; e a variação por métrica supera a da classificação geral.

- **RQ 08 (*rework rate*):** *rework rate* mediano entre 20% e 40%, maior que o CFR (b) e fortemente correlacionado com ele, porque conta as próprias releases corretivas, inclusive as publicadas depois de 7 dias.

2. Metodologia

2.1. Fonte de dados e seleção

Os dados vêm da API do GitHub (REST e, para as tags, GraphQL), consultada por um *pipeline* próprio em Python, com cache em disco e retomada. Seguimos as definições operacionais comuns da disciplina: janela de 01/10/2025 a 30/09/2026 (UTC), apenas o *default branch* e inclusão dos repositórios que usam o GitHub Actions e têm, na janela, ao menos 5 releases e 50 execuções de *workflow* válidas. Os candidatos, com mais de 1.000 estrelas, foram percorridos por estrelas decrescente até o 300º aprovado (Tabela 1). A amostra reúne, portanto, os repositórios mais populares que passam no funil, e não é um sorteio (de 40.681 a 391.478 estrelas, mediana de 62.559). Para não perder execuções em repositórios muito ativos, os meses que atingem o teto de 1.000 resultados da API são consultados de novo por dia e, se preciso, por hora.

Tabela 1. Funil de seleção dos repositórios.

Candidatos	Examinados	Sem Actions	$<$ 5 releases	$<$ 50 execuções	Amostra final
5.620	712	70	296	46	300

2.2. Definições operacionais

A Tabela 2 resume as definições, que seguem as comuns da disciplina, e as variantes usadas nas RQ 02, 03 e 07. Cada métrica recebe uma nota de 4 (*Elite*) a 1 (*Low*) pelos cortes adaptados do DORA [DORA 2024], e a categoria geral é a mediana das notas, arredondada para baixo. A RQ 07 compara três combinações: C1 (release, lead time (a) e CFR (a)), C2 (release e pré-release, lead time (b) e CFR (b)) e C3 (tag, lead time (b) e CFR (a)). Duas decisões são do grupo: episódios que já começam falhando na janela são censurados, como os que não terminam nela; e o *rework rate* só considera releases com commits conhecidos, o que exclui a primeira release da história.

Tabela 2. Definições operacionais e variantes (todas calculadas por repositório, na janela).

Métrica	Definição
Deploy	Release publicada, nem rascunho nem pré-release (variantes: com pré-releases; tags)
Frequência	Deploys divididos pelas 52,14 semanas da janela
Lead time	(a) release − commit mais antigo, mediana das releases; (b) release − cada commit, mediana dos commits
CFR	(a) execuções com falha ÷ (falhas + sucessos); (b) releases seguidas em até 7 dias por uma corretiva ÷ releases avaliadas, sem as dos últimos 7 dias
Recuperação	Mediana, por *workflow*, do tempo da primeira falha ao sucesso seguinte; episódios sem início ou fim na janela são censurados
Rework rate	Releases corretivas ÷ releases com commits conhecidos

2.3. Validação manual

Sorteamos 60 repositórios (semente 42) da lista prevista de aprovados e 5 releases de cada um (300 releases). Os três autores rotularam a amostra de forma independente, sem ver a saída da heurística, segundo um protocolo escrito antes do sorteio: o tipo do projeto, se as releases são entregas reais ao usuário e se cada release é corretiva. O consenso é o rótulo da maioria; os 55 itens com divergência (2–1) foram revisados em reunião, e nenhum rótulo mudou. O kappa de Fleiss foi de 0,82 no tipo do projeto (quase perfeita), 0,19 nas entregas reais (leve) e 0,78 nas releases corretivas (substancial) [Landis and Koch 1977]. O valor baixo em entregas reais decorre da prevalência do rótulo "sim": os três concordaram em 53 dos 60 repositórios (88%). Contra o consenso (73 corretivas), a heurística de release corretiva teve F1 de 0,415 na versão 1 (número da versão e palavras-chave nos commits), de 0,606 na versão 2 (que lê as *release notes*) e de 0,644 na versão 3 (notas lidas por seção e maioria de commits de correção; precisão de 0,632 e *recall* de 0,658). A versão 3, usada no CFR (b) e no *rework rate*, não atinge a meta de 0,70.

2.4. Análise estatística

Como pede a disciplina, as métricas são resumidas por mediana e IQR; a RQ 05 usa a correlação de Spearman; a RQ 06, o teste de Kruskal-Wallis com correção de Holm sobre todos os testes e ε^2 como tamanho de efeito, sem os grupos com menos de 5 valores; e a RQ 07, o kappa de Cohen ponderado linear. Na RQ 08, o *rework rate* é comparado ao CFR (b) pelo teste de Wilcoxon pareado unilateral.

3. Resultados das RQ 01 a RQ 04

Os resultados descrevem os 300 repositórios da amostra. As métricas, muito assimétricas, são resumidas por mediana e IQR (Tabela 3) e classificadas nas faixas DORA (Figura 1), e a Tabela 4 resume o veredito de cada hipótese. Na classificação geral (C1), 24 repositórios (8,0%) são *Elite*, 131 (43,7%) *High*, 130 (43,3%) *Medium* e 15 (5,0%) *Low*; em 17, uma das quatro métricas não pôde ser calculada, e a categoria usa as demais.

Tabela 3. Estatísticas descritivas das métricas (n = repositórios com valor definido; Indef. = repositórios sem valor).

Métrica	n	Indef.	Mediana	Q1	Q3	Mín.	Máx.
Deploys por semana	300	0	0,54	0,25	1,23	0,10	49,56
Lead time (a), h	299	1	255,7	73,2	952,8	0,01	50 634
Lead time (b), h	299	1	277,0	77,2	1 250,7	0,01	107 152
CFR (a), %	300	0	4,7	2,3	11,1	0,0	90,1
CFR (b), %	298	2	17,4	5,9	32,8	0,0	88,1
Recuperação, h	284	16	2,56	0,98	6,59	0,07	181,8
Episódios censurados, %	289	11	1,1	0,0	5,3	0,0	100,0

3.1. RQ 01: frequência de deploy

A faixa *Medium* reúne 135 repositórios (45,0%), seguida da *High* (83; 27,7%), da *Low* (74; 24,7%) e da *Elite* (8; 2,7%), e o repositório mais frequente publica 49,6 releases por semana, quase cem vezes a mediana. A *Medium* é maioria relativa, e não absoluta. Chama a atenção a cauda lenta: um quarto dos projetos populares publica menos de uma release por mês, o que reforça que estrelas não indicam cadência de entrega.

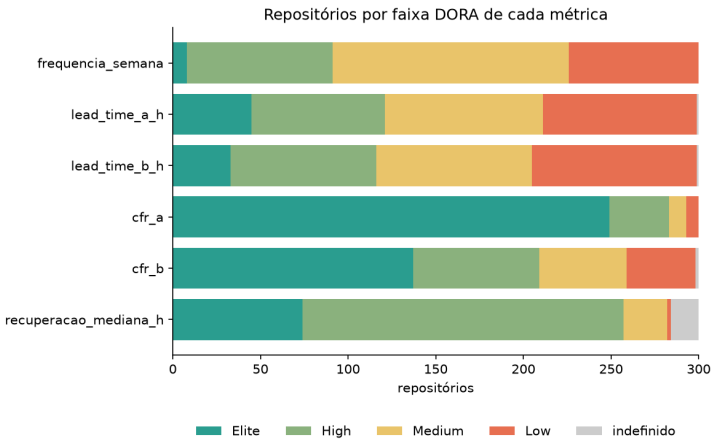


Figura 1. Repositórios por faixa DORA em cada métrica (cinza: métrica indefinida).

Tabela 4. Hipóteses das RQ 01 a RQ 04 frente aos resultados.

RQ	Hipótese	Resultado
01	*Medium* mais comum, *Elite* minoria, *Low* com 5 a 11 releases	Confirmada (*Medium* com 45%)
02	Dias a poucas semanas, na maioria *Medium* e *High*	Confirmada
02	Variante (a) maior e com mais *Low* que a (b)	Refutada (88 *Low* contra 94)
03	CFR baixo na maioria, com grande dispersão	Confirmada
03	CFR (a) maior que CFR (b)	Refutada (4,7% contra 17,4%)
04	Menos de um dia, mediana *High*, com censura	Confirmada
04	Poucos *Elite*, IQR amplo e cauda de dias a semanas	Parcial (26,1% *Elite*; IQR estreito)

3.2. RQ 02: lead time

O lead time mediano é de 10,7 dias na variante (a) e de 11,5 dias na (b), com distribuições parecidas: na (a), 45 repositórios são *Elite*, 76 *High*, 90 *Medium* e 88 *Low*; na (b), 33, 83, 89 e 94. A variante (a) é maior em 58,9% dos repositórios, mas por pouco, e a diferença não aparece na distribuição agregada. Uma explicação plausível, não testada, é que a (b) pondera cada commit e dá mais peso às releases grandes, enquanto a (a) dá o mesmo peso a cada release.

3.3. RQ 03: taxa de falha de mudanças

No CFR (a), 83,0% dos repositórios são *Elite*; no CFR (b), 46,0% são *Elite*, 24,2% *High*, 16,8% *Medium* e 13,1% *Low*. Ao contrário do esperado, a variante (a) é menor em 67,1% dos repositórios, provavelmente porque divide as falhas por todas as execuções de CI, enquanto a (b) divide por poucas releases (mediana de 28). A (a) mede falha de *pipeline*, e não de produção; a (b) se aproxima mais do DORA, mas depende da heurística de release corretiva (Seção 2.3) e deve ser lida como estimativa ruidosa.

3.4. RQ 04: tempo de recuperação

Dos 284 repositórios com valor, 90,5% se recuperam em menos de um dia: 26,1% são *Elite*, 64,4% *High*, 8,8% *Medium* e 0,7% *Low*. Dezesseis ficam sem valor, por não terem episódio de falha completo, e 0,9% dos 64 672 episódios são censurados. A cauda longa esperada não aparece (só 2 repositórios chegam a uma semana, e o IQR é estreito), e os *Elite* são mais de um quarto.

4. Resultados das RQ 05 e RQ 06

Esta seção relaciona velocidade e estabilidade (RQ 05) e compara as métricas entre grupos de repositórios (RQ 06). A Tabela 5 resume o veredito de cada hipótese.

Tabela 5. Hipóteses das RQ 05 e RQ 06 frente aos resultados.

RQ	Hipótese	Resultado
05	CFR (a): correlação fraca com a frequência	Confirmada ($\rho = 0{,}16$)
05	CFR (b): correlação positiva e moderada	Confirmada, no limite com forte ($\rho = 0{,}50$)
05	As variantes levam a conclusões diferentes	Confirmada
06	Efeitos maiores em contribuidores e tipo	Parcial: só contribuidores, no lead time
06	Efeitos pequenos em estrelas, linguagem e idade	Refutada para idade e linguagem (lead time)
06	Poucos testes significativos após Holm	Confirmada (4 de 20)

4.1. RQ 05: frequência de deploy e taxa de falha

A correlação de Spearman entre a frequência de deploy e o CFR (a) é positiva e fraca ($\rho = 0{,}162$; $p = 0{,}005$; n = 300); com o CFR (b), é positiva e está no limite entre moderada e forte ($\rho = 0{,}501$; $p < 0{,}001$; n = 298), como mostra a Figura 2. Com o CFR (a), os dados estão em linha com o DORA: publicar mais vezes quase não se associa a mais falhas de CI. Com o CFR (b), sugerem um *trade-off*, mas em boa parte por construção da métrica, como previsto na hipótese. Como esperado, as duas variantes levam a conclusões diferentes, e nenhuma das correlações implica causalidade.

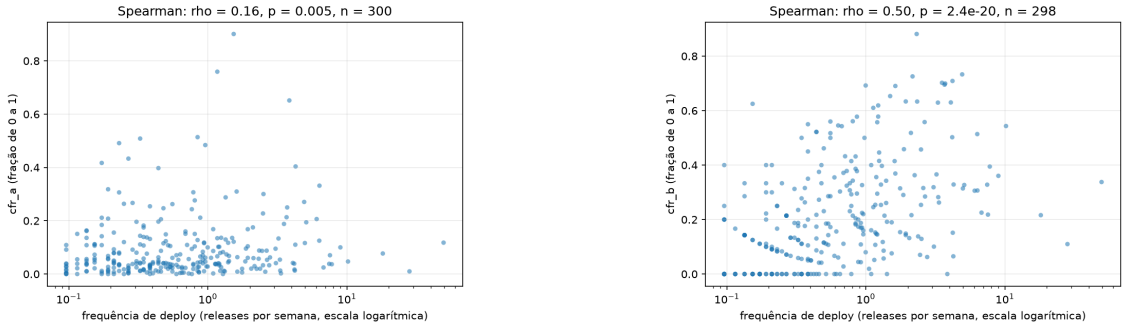


Figura 2. Frequência de deploy (escala logarítmica) contra CFR (a), à esquerda, e contra CFR (b), à direita.

4.2. RQ 06: características associadas ao desempenho

Dos 20 testes, só 4 permanecem significativos após a correção de Holm, três deles no lead time (a) (Tabela 6). O maior efeito é o da idade: do quartil mais novo para o mais antigo, o lead time mediano cresce de 51 h para 1 024 h ($\varepsilon^2 = 0{,}365$, grande) e a frequência cai de 0,94 para 0,36 release por semana ($\varepsilon^2 = 0{,}118$, médio). Repositórios com mais contribuidores também têm lead time maior (de 131 h no primeiro quartil para 981 h no último; $\varepsilon^2 = 0{,}183$, médio), e a linguagem tem efeito médio no lead time, com medianas de 131 h em Python a 658 h no grupo *outras*. O CFR (a) e a recuperação não diferem em nenhum fator. O tipo do projeto foi testado em 58 dos 60 repositórios da amostra-ouro (o grupo *outro*, com 2, ficou abaixo do mínimo de 5), sem diferença significativa.

O tipo do projeto não mostrou diferença, possivelmente por falta de poder, e a idade, de que esperávamos efeito pequeno, tem o maior. Uma explicação plausível, não testada, é que projetos mais antigos e maiores acumulam mudanças por mais tempo antes de cada release.

Tabela 6. Comparação das métricas entre os grupos de cada fator (Kruskal-Wallis): ε^2 e, entre parênteses, p corrigido por Holm sobre os 20 testes. Em negrito, os significativos ($p < 0{,}05$). Na recuperação, n é menor (284; 54 no tipo do projeto).

Fator	n	Frequência	Lead time (a)	CFR (a)	Recuperação
Linguagem	300	0,051 (0,14)	**0,095 (< 0,001)**	0,036 (0,76)	0,029 (1,00)
Estrelas	300	0,014 (1,00)	0,018 (1,00)	0,005 (1,00)	0,009 (1,00)
Contribuidores	300	0,010 (1,00)	**0,183 (< 0,001)**	0,008 (1,00)	0,012 (1,00)
Idade	300	**0,118 (< 0,001)**	**0,365 (< 0,001)**	0,016 (1,00)	0,038 (0,20)
Tipo do projeto	58	0,033 (1,00)	0,042 (1,00)	0,002 (1,00)	0,123 (0,54)

5. Resultados da RQ 07

A RQ 07 compara a classificação geral dos repositórios nas combinações C1, C2 e C3 (Seção 2.2), repositório a repositório, pelo percentual que muda de categoria e pelo kappa de Cohen ponderado linear. Ficam fora do par os repositórios com C2 ou C3 indefinida: `zed-industries/zed` (sem lead time (b) e CFR (b) em C2) e `docling-project/docling` (sem as tags de C3), porque a API devolveu HTTP 422 em uma consulta de cada um. Por isso os pares têm 299, 299 e 298 repositórios.

Tabela 7. Concordância entre as classificações gerais de cada par de combinações (Mudam = repositórios que trocam de categoria; Vizinha = trocas de uma só categoria; Sobem e Descem = sentido da troca de x para y).

Par ($x \times y$)	n	Mudam	%	Vizinha	Sobem	Descem	κ
C1 × C2	299	90	30,1	83	26	64	0,544 (moderada)
C1 × C3	299	65	21,7	61	49	16	0,685 (substancial)
C2 × C3	298	85	28,5	82	81	4	0,591 (moderada)

Entre 21,7% e 30,1% dos repositórios mudam de categoria conforme a definição (Tabela 7), 92% a 97% delas para uma categoria vizinha, e nenhum vai de *Elite* para *Low*, ou o contrário. A Figura 3 mostra que, em C1×C2, só 6 dos 24 repositórios *Elite* de C1 continuam *Elite* (13 passam a *High* e 5 a *Medium*), enquanto em C1×C3 17 dos 24 continuam.

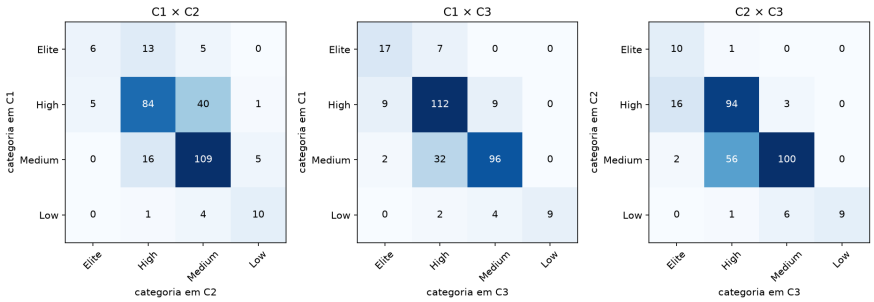


Figura 3. Matrizes de transição entre as categorias gerais de cada par de combinações (as linhas são a categoria na primeira combinação, e as colunas, na segunda).

A distribuição agregada também muda: os *Elite* são 24 em C1, 11 em C2 e 28 em C3, e a categoria mais comum é a *High* em C1 (por um repositório) e em C3 (51,2%), mas a *Medium* em C2 (52,8%).

A Tabela 8 mostra de onde vêm as trocas. O CFR muda de faixa em 59,3% dos repositórios entre C2 e as demais, quase sempre para pior em C2, cujo CFR (b) tem

Tabela 8. Mudança de faixa de cada métrica entre as combinações: % de repositórios cuja nota muda e, entre parênteses, quantos sobem e quantos descem de x para y. O CFR de C1 e C3 é o mesmo (CFR (a)).

	C1 × C2	C1 × C3	C2 × C3
Frequência de deploy	10,7 (32/0)	25,1 (75/0)	15,1 (45/0)
Lead time	43,6 (66/64)	46,6 (75/64)	10,1 (21/9)
CFR	59,3 (29/147)	0,0 (0/0)	59,3 (147/29)
Classificação geral	30,1 (26/64)	21,7 (49/16)	28,5 (81/4)

Tabela 9. Hipóteses da RQ 07 frente aos resultados.

Hipótese	Resultado
20% a 40% mudam de categoria em cada par	Confirmada (21,7% a 30,1%)
Mudanças quase sempre para uma categoria vizinha	Confirmada (92% a 97%)
Kappa ponderado moderado a substancial	Confirmada (0,544 a 0,685)
C2 e C3 levam a categorias melhores que C1	Confirmada só para C3
Pré-releases e tags aumentam a frequência	Confirmada
Lead time (b) menor que o (a)	Parcial: só em C3
Maior divergência em C1×C2, menor em C2×C3	Parcial: a menor é C1×C3
Variação por métrica maior que a da geral	Parcial: não na frequência

mediana de 17,0%, contra 4,7% do (a). O lead time muda em 43,6% a 46,6% entre C1 e as demais, nos dois sentidos (medianas de 255,7 h em C1, 264,1 h em C2 e 215,6 h em C3), mas em só 10,1% entre C2 e C3, que usam a mesma variante. A frequência só sobe: a mediana passa de 0,54 para 0,65 (C2) e 0,88 (C3) por semana. Como a categoria geral é a mediana de quatro notas, parte das trocas é absorvida.

5.1. Discussão

A escolha da definição não inverte o desempenho de um repositório, mas desloca a categoria de cerca de um em quatro e muda a categoria mais comum. Só C3 leva a categorias melhores, porque em C2 a piora do CFR supera o ganho de frequência; e a menor divergência é em C1×C3, porque o que importa não é quantas definições os pares compartilham, mas quais: C1 e C3 compartilham o CFR (a), a métrica que mais muda de faixa. Para as RQ 01 a RQ 06, os valores por repositório devem ser lidos como estimativas, mas as conclusões gerais se mantêm: os repositórios seguem concentrados em *High* e *Medium* nas três combinações.

6. Resultados da RQ 08

O *rework rate* tem mediana de 31,1% (IQR de 14,2% a 52,5%; n = 300), e 29 repositórios não têm nenhuma release corretiva. Ele é fortemente correlacionado com o CFR (b) ($\rho = 0{,}706$; n = 298) e é maior que ele em 223 dos 298 pares, igual em 56 e menor em 19 (Wilcoxon pareado unilateral, $p < 0{,}001$; correlação rank-biserial de 0,975), como mostra a Figura 4. As três hipóteses avaliadas se confirmam: a mediana fica entre 20% e 40%, o *rework rate* é maior que o CFR (b) e a correlação entre eles é forte. A evolução temporal não foi avaliada, por decisão de escopo.

A diferença vem das definições: o CFR (b) atribui a falha à release corrigida e só conta correções publicadas em até 7 dias, enquanto o *rework rate* conta as próprias releases corretivas, inclusive as posteriores a esse prazo. Nos 19 repositórios em que ele é menor, o numerador das duas métricas é o mesmo, e a diferença, de até 1,3 ponto percentual, vem da censura do CFR (b), que exclui do denominador as releases dos últimos

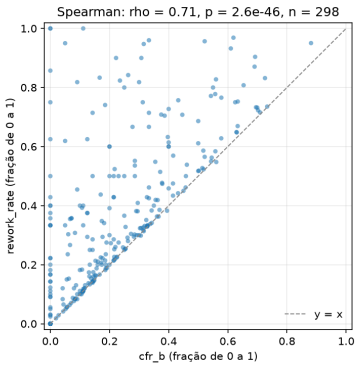


Figura 4. CFR (b) contra *rework rate*; acima da diagonal $y = x$, o *rework rate* é maior.

7 dias da janela. Como as duas dependem da mesma heurística (Seção 2.3), parte da correlação vem dos mesmos erros de classificação.

7. Ameaças à validade

Organizamos as ameaças nas quatro categorias clássicas [Wohlin et al. 2012].

Construto. Nenhuma das métricas é observada diretamente. Tratar uma release como deploy só vale se ela chega a quem usa o projeto: o consenso da amostra-ouro foi que sim em 59 dos 60 repositórios, mas com kappa de 0,19 e cobrindo só 60 dos 300 (no `supabase`, as "releases" são boletins mensais). O CFR (a) mede falha de CI, e não de produção, e o CFR (b) e o *rework rate* herdam os erros da heurística de release corretiva (Seção 2.3). O lead time usa a data de autoria do commit, que pode anteceder a sua entrada no ramo (*rebase*, *cherry-pick*), e 6 releases com a tag apagada ou reescrita ficaram fora. A recuperação mede a volta do CI, e não do serviço.

Interna. A idade tem o maior efeito da RQ 06 e pode se sobrepor a outros fatores, como o número de contribuidores, o que a análise por fator isolado não separa, e as correlações da RQ 05 não implicam causalidade. As regras da heurística foram escolhidas a partir dos erros nos mesmos 300 itens usados para avaliá-la, o que torna o F1 otimista, e os autores foram também os avaliadores, risco atenuado pelo protocolo prévio e pela rotulagem independente.

Externa. A amostra reúne os 300 repositórios mais populares que passam no funil, e não é um sorteio, e os critérios de inclusão favorecem projetos que publicam releases no GitHub. Os resultados não se estendem a projetos pequenos, corporativos ou de outras plataformas, nem necessariamente a outros períodos, e 14 organizações têm mais de um repositório (até 6), o que reduz a independência das observações.

Conclusão. Só 4 dos 20 testes da RQ 06 permanecem significativos após a correção de Holm, e os do tipo do projeto, com 58 repositórios, têm pouco poder. Os quartis são um agrupamento arbitrário, e os testes não paramétricos não ajustam um fator pelos demais.

A correlação de Spearman tem muitos empates (11 repositórios com CFR (a) igual a zero e 61 com CFR (b) igual a zero), o kappa de Fleiss é sensível à prevalência, e valores próximos de um corte podem mudar de categoria por diferenças pequenas.

8. Conclusão

Mineramos as quatro métricas DORA em 300 repositórios populares do GitHub que usam GitHub Actions, em um ano, com duas variantes do lead time e do CFR. O projeto mediano publica uma release a cada duas semanas, leva cerca de 11 dias do commit à release, tem CFR de CI de 4,7% e se recupera de uma execução com falha em 2,6 horas. Na classificação geral, 87% ficam em *High* ou *Medium* e só 8% em *Elite*.

A variante escolhida importa: o CFR (b) tem mediana quase quatro vezes maior que a do CFR (a), ao contrário do que esperávamos. A frequência de deploy tem correlação positiva com as duas variantes do CFR (ρ de 0,16 e de 0,50), o que não confirma que velocidade e estabilidade andem juntas, embora o resultado com o CFR (b) seja em parte efeito da definição. Na RQ 06, só 4 dos 20 testes seguem significativos após a correção de Holm, e a idade é o fator mais associado ao desempenho. O *rework rate* tem mediana de 31% e correlação forte com o CFR (b) (ρ de 0,71). Trocar as definições muda a categoria geral de 22% a 30% dos repositórios, quase sempre para uma vizinha: as conclusões gerais se mantêm, mas a categoria de cada repositório deve ser lida como estimativa.

O principal limite é a heurística de release corretiva, que sustenta o CFR (b) e o *rework rate*: o seu F1 de 0,644 não atingiu a meta de 0,70, e as regras foram escolhidas sobre os mesmos itens da avaliação. Um próximo passo é validar a heurística em uma amostra maior e separada, e comparar as aproximações com dados reais de deploy e de incidentes.

Disponibilidade. O *pipeline*, os dados e as análises estão em `https://github.com/gabialvarenga/lab-experimentacao-software`, e o quadro de acompanhamento do projeto, em `https://github.com/users/gabialvarenga/projects/9`.

Referências

DORA (2024). Accelerate State of DevOps Report 2024. Google Cloud. Disponível em: `https://dora.dev/research/2024/dora-report/`.

Forsgren, N., Humble, J., and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution Press, Portland, OR.

Landis, J. R. and Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.

Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., and Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer, Berlin, Heidelberg.